

Perbandingan Metode Modified Z-Score dan Isolation Forest dalam Deteksi Outlier pada Data Time-Series Ketinggian Gelombang Laut



Mata Kuliah : IF25-32025 / Penambangan Data
Dosen Pengampu : Meida Cahyo Untoro, S.Kom., M.Kom

Disusun Oleh :

Ade Putri Tifani	123140011
Natasya Felisita Br Ginting	123140017
Memory Simanjuntak	123140095
Silvia	123140133
Nadya Shafwah Yusuf	123140167
Mega Zayyani	123140180
Yuni Okta Safitri	123140213

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
2026

DAFTAR ISI

DAFTAR ISI.....	2
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	2
1.3 Tujuan Penelitian.....	2
1.4 Batasan Masalah.....	2
BAB II TINJAUAN PUSTAKA.....	4
2.1 Data Mining dan Preprocessing.....	4
2.2 Outlier.....	5
2.3 Metode Deteksi Outlier.....	6
2.4 Metrik Evaluasi.....	7
2.5 Penelitian Terkait.....	9
2.5.1 Outlier Detection Performance of a Modified Z-Score Method in Time-Series RSS Observation With Hybrid Scale Estimators.....	9
2.5.2 Research on the effectiveness of different outlier detection methods in common data distribution types.....	9
2.5.3 An Outliers Detection and Elimination Framework in Classification Task of Data Mining.....	10
2.5.4 Isolation Forest: An Algorithm for Anomaly Detection.....	10
2.5.5 Australian Ocean Surface Waves Dataset from SAR.....	10
BAB III METODOLOGI PENELITIAN.....	12
3.1 Alur Penelitian.....	12
3.2 Deskripsi Dataset.....	14
3.3 Prosedur Eksperimen.....	16
3.3.1 Pembagian Data (Train-Test Split).....	16
3.3.2 Metode yang Digunakan.....	16
3.3.3 Algoritma Klasifikasi.....	17
3.3.4 Metrik Evaluasi.....	18
BAB IV HASIL DAN PEMBAHASAN.....	20
4.1 Eksplorasi Data (EDA).....	20
4.1.1 Gambaran Umum Dataset.....	20
4.1.2 Distribusi Fitur.....	21
4.1.3 Distribusi Kelas Target.....	23
4.2 Outlier Detection.....	24
4.2.1 Deteksi Outlier—Boxplot Visual.....	24
4.2.2 Deteksi Outlier—2 Metode + Tabel Ringkasan.....	24

4.3 Treatment.....	25
4.3.1 Treatment—Strategi.....	25
4.3.2 Visualisasi Before vs After Treatment.....	25
4.3.3 Evaluasi Dampak Treatment terhadap Klasifikasi.....	26
4.4 Hasil Perbandingan Metode.....	26
4.4.1 Tabel Perbandingan Performa.....	26
4.4.2 Visualisasi Perbandingan.....	27
4.5 Pembahasan.....	30
BAB V KESIMPULAN DAN SARAN.....	33
5.1 Kesimpulan.....	33
5.2 Saran.....	33
DAFTAR PUSTAKA.....	35
LAMPIRAN.....	36

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pesatnya perkembangan teknologi informasi saat ini memperluas pemanfaatan data di berbagai sektor, terutama dalam mendukung proses analisis dan pengambilan keputusan. Dalam konteks ini, kualitas data menjadi aspek krusial karena berkorelasi langsung terhadap akurasi informasi yang dihasilkan. Data yang masih mengandung kesalahan, noise, atau nilai yang tidak wajar dapat menghasilkan simpulan yang bias dan tidak menggambarkan kondisi sebenarnya. Oleh karena itu, tahap preprocessing sangat diperlukan untuk memastikan data benar-benar bersih dan siap dianalisis.

Salah satu permasalahan yang sering muncul dalam pengolahan data adalah adanya outlier. Outlier merupakan nilai yang berbeda jauh dari pola umum data. Nilai ini dapat muncul karena kesalahan pengukuran, gangguan sistem, atau kondisi tertentu yang bersifat ekstrem. Keberadaan outlier dapat memengaruhi distribusi data dan mengubah hasil analisis. Jika tidak ditangani dengan baik outlier dapat menurunkan akurasi model yang digunakan [1]. Masalah ini semakin penting pada data time-series seperti data gelombang laut yang bersifat dinamis.

Data gelombang laut memiliki karakteristik yang fluktuatif karena dipengaruhi oleh faktor lingkungan seperti angin dan cuaca. Selain itu, data yang bersumber dari sensor maupun pengamatan satelit, seperti Synthetic Aperture Radar (SAR), kerap mengandung noise dan ketidakkonsistenan nilai, sehingga pembersihan data menjadi langkah wajib sebelum analisis lanjut dilakukan [2]. Salah satu metode statistik yang efektif untuk mengatasi hal ini adalah *Modified Z-Score*. Metode ini menggunakan median dan *Median Absolute Deviation* (MAD), sehingga lebih robust (stabil) terhadap data yang tidak berdistribusi normal dibandingkan metode standar lainnya [3].

Selain pendekatan statistik, teknik machine learning seperti Isolation Forest juga mulai banyak diadopsi untuk deteksi outlier. Berbeda dengan metode statistik konvensional, Isolation Forest bekerja dengan mengisolasi data melalui struktur pohon, data yang lebih cepat terisolasi diidentifikasi sebagai outlier [4]. Perbedaan cara kerja dari kedua metode inilah yang menjadi alasan perlunya dilakukan studi perbandingan.

Oleh karena itu, penelitian ini bertujuan untuk membandingkan efektivitas Modified Z-Score dan Isolation Forest pada data gelombang laut berbasis time-series guna menentukan metode yang paling optimal dalam meningkatkan kualitas data.

Perbedaan pendekatan antara metode statistik dan metode berbasis machine learning menunjukkan perlunya analisis komparatif untuk menentukan metode yang lebih efektif dalam mendeteksi outlier pada data time-series gelombang laut yang bersifat dinamis.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana efektivitas Modified Z-Score dibandingkan Isolation Forest dalam mendeteksi outlier pada data time-series gelombang laut?
2. Metode manakah yang lebih mampu memisahkan noise tanpa menghilangkan pola utama data?
3. Bagaimana dampak pembersihan outlier terhadap perubahan distribusi data dan penurunan nilai ekstrem yang tidak representatif?

1.3 Tujuan Penelitian

Tujuan yang ingin dicapai dalam penelitian ini adalah:

1. Mengimplementasikan metode Modified Z-Score dan Isolation Forest untuk mendeteksi outlier pada data Significant Wave Height (Hsig).
2. Membandingkan performa kedua metode berdasarkan hasil deteksi serta perubahan distribusi data setelah proses pembersihan.
3. Menganalisis dampak preprocessing terhadap kualitas data melalui penurunan nilai ekstrem dan perbaikan distribusi data.

1.4 Batasan Masalah

Batasan masalah dalam penelitian ini ditetapkan sebagai berikut.

1. Data yang digunakan merupakan data ketinggian gelombang laut (Significant Wave Height/Hsig) berbasis time-series yang diperoleh dari dataset pengamatan satelit (SAR).
2. Data yang dianalisis dibatasi pada rentang data yang tersedia dalam dataset tanpa penambahan sumber eksternal.

3. Metode deteksi outlier yang digunakan dibatasi pada Modified Z-Score dan Isolation Forest.
4. Analisis difokuskan pada tahap preprocessing, khususnya pada proses deteksi dan pembersihan outlier.
5. Evaluasi dilakukan dengan membandingkan kondisi data sebelum dan sesudah preprocessing, terutama dalam melihat perubahan distribusi dan nilai ekstrem.
6. Data dianalisis dalam bentuk time-series tanpa mempertimbangkan aspek spasial atau lokasi geografis.

BAB II

TINJAUAN PUSTAKA

2.1 Data Mining dan Preprocessing

Data mining merupakan rangkaian proses untuk mengekstraksi pola maupun informasi yang tersembunyi dari sekumpulan data dalam jumlah besar dengan memanfaatkan teknik statistik, matematis, serta algoritma machine learning. Proses ini merupakan bagian dari Knowledge Discovery in Databases (KDD) yang terdiri dari beberapa tahapan yaitu pemilihan data, pembersihan, transformasi, hingga interpretasi hasil. Dalam proses ini kualitas data menjadi faktor yang sangat penting karena data yang tidak berkualitas dapat menghasilkan model yang tidak akurat dan memicu bias saat melakukan analisis [5].

Tahap preprocessing data merupakan bagian penting dalam data mining yang bertujuan untuk mempersiapkan data agar siap digunakan dalam proses pemodelan. Preprocessing mencakup beberapa tahapan utama seperti data cleaning, integrasi data, transformasi, serta reduksi data. Pada realitanya dataset sering kali mengandung berbagai permasalahan seperti missing value, noise, inkonsistensi serta nilai ekstrim. Maka pada proses preprocessing diperlukan untuk meningkatkan kualitas data sehingga hasil analisis yang diperoleh menjadi lebih optimal dan dapat dipercaya [5].

Salah satu kendala sering ditemui pada tahap preprocessing yaitu munculnya outlier yakni data yang memiliki nilai menyimpang secara signifikan dibandingkan dengan mayoritas data lainnya. Munculnya outlier ini bisa disebabkan oleh banyak hal mulai dari kendala teknis saat pengukuran, kelalaian dalam input data, hingga memang adanya fenomena langka yang tertangkap dalam rekaman data. Outlier ini seringkali mengacaukan sebaran data dan merusak kalkulasi statistik dasar seperti mean maupun standar deviasi. Keberadaan outlier akan mengganggu proses pembelajaran model yang pada akhirnya justru menurunkan performa dan akurasi prediksi secara keseluruhan [6].

Oleh karena itu diperlukan proses deteksi dan penanganan outlier yang tepat dalam tahap preprocessing. Beberapa metode yang umum digunakan antara lain pendekatan statistik seperti Modified Z-Score sebagai pendekatan statistik robust serta pendekatan berbasis machine learning seperti Isolation Forest. Pemilihan metode harus disesuaikan dengan karakteristik data karena setiap metode memiliki kelebihan dan

keterbatasan masing-masing. Dengan penanganan outlier yang presisi, kualitas data akan meningkat sehingga model yang dibangun nantinya bisa lebih stabil dan akurat serta dapat dipertanggungjawabkan [6].

2.2 Outlier

Dalam analisis data, sering kali ditemukan observasi yang nilainya menyimpang secara signifikan dari kelompok data mayoritas, yang lazim disebut sebagai outlier [7]. Istilah outlier kerap disamakan dengan anomali, meskipun keduanya memiliki fokus yang berbeda. Anomali lebih merujuk pada perilaku atau pola tidak wajar yang bersumber dari sistem yang berbeda, sedangkan outlier secara spesifik menyoroti titik data ekstrem yang menyimpang jauh di luar batas distribusi normal. Berdasarkan jumlah variabelnya, outlier dapat diklasifikasikan menjadi tipe univariat dan multivariat. Outlier univariat terjadi apabila nilai ekstrem tersebut hanya muncul pada satu variabel tunggal. Hal ini berbeda dengan outlier multivariat; pada kasus ini, nilai pada masing-masing variabel mungkin tampak wajar jika dievaluasi secara terpisah, namun ketika digabungkan, kombinasi nilai tersebut membentuk pola yang sangat menyimpang.

Kemunculan data yang menyimpang dalam sebuah dataset umumnya dilatarbelakangi oleh dua faktor utama. Faktor pertama murni disebabkan oleh kesalahan teknis, yang sering disebut sebagai erroneous outlier. Contoh dari faktor ini meliputi malfungsi sensor perekam, kelalaian manusia saat memasukkan data, hingga adanya gangguan (noise) dalam transmisi sinyal. Namun demikian, tidak semua outlier merupakan data yang tidak berguna. Faktor kedua adalah legitimate extreme, yaitu kejadian ekstrem yang valid dan benar-benar terjadi di dunia nyata. Nilai ekstrem yang valid seperti ini tidak boleh dihapus begitu saja, karena sering kali menyimpan informasi penting untuk menemukan pola tak terduga dalam proses data mining. [8].

Apabila keberadaan outlier dibiarkan tanpa penanganan khusus pada tahap pra-pemrosesan, hal tersebut dapat memberikan dampak negatif yang signifikan terhadap model yang dibangun. Dari perspektif statistik dasar, keberadaan nilai yang terlalu ekstrem dapat memengaruhi nilai rata-rata (mean) secara drastis dan memperlebar standar deviasinya. Akibatnya, perhitungan statistik tersebut menjadi

kurang representatif dalam mewakili kondisi mayoritas data, sehingga sering kali diperlukan metrik yang lebih tangguh (robust) terhadap outlier seperti median

Dampak negatif ini juga berpengaruh pada pemodelan machine learning, misalnya pada kasus regresi linier. Sebuah outlier dengan pengaruh (leverage) yang tinggi dapat menggeser garis regresi menjauhi tren data yang sebenarnya. Akibatnya, akurasi model bisa menurun drastis dan rentan mengalami overfitting, karena model menjadi terlalu fokus mempelajari data anomali (noise) daripada mengenali pola data yang sebenarnya [7].

2.3 Metode Deteksi Outlier

Modified Z-Score merupakan pengembangan dari Z-Score standar yang menggantikan penggunaan mean dan standar deviasi dengan median dan Median Absolute Deviation (MAD). Substitusi ini menjadikan metode ini lebih kuat terhadap data yang tidak berdistribusi normal maupun data yang sudah mengandung outlier, karena median tidak terpengaruh oleh nilai ekstrem seperti halnya mean [1].

Isolation Forest merupakan metode berbasis *machine learning* yang menggunakan prinsip isolasi data menggunakan *decision tree* secara acak. Isolation Forest membedakan metode statistik yang menghitung jarak sebuah titik dari pusat distribusi. Sementara data biasa membutuhkan lebih banyak pemisahan untuk diisolasi, data yang anomali cenderung memiliki sedikit tetangga, yang memungkinkan isolasi lebih cepat pada kedalaman pohon yang lebih rendah [10]. Metode ini efektif untuk dataset berskala besar karena tidak memerlukan asumsi distribusi data tertentu.

Tabel 1. Metode Deteksi Outlier

Metode	Tipe	Prinsip Kerja	Asumsi	Threshold
Modified Z-Score	Statistik robust	Menggunakan median dan MAD: $M_i = \frac{0.6745(x_i - \text{median})}{MAD}$ Dengan MAD: $MAD = \text{median}(x_i - \text{median})$	Tidak perlu distribusi normal, median lebih representatif, robust terhadap outlier	$ M_i > 3.5$

Isolation Forest	Machine Learning	Mengisolasi data melalui <i>decision tree</i> , data yang lebih cepat terisolasi diidentifikasi sebagai outlier	Tidak memerlukan asumsi	Contaminasi on parameter (default 0.1)
------------------	------------------	---	-------------------------	--

2.4 Metrik Evaluasi

Pada penelitian ini, metrik evaluasi digunakan untuk mengukur seberapa baik proses deteksi dan penghapusan outlier dalam meningkatkan kualitas data serta performa model klasifikasi. Karena outlier biasanya jumlahnya sedikit (minoritas), maka evaluasi tidak cukup hanya menggunakan accuracy, tetapi perlu metrik lain yang lebih relevan.

1. Accuracy

Accuracy digunakan untuk melihat proporsi prediksi yang benar dari seluruh data.

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

Namun, dalam kasus deteksi outlier, accuracy kurang informatif karena jumlah data normal jauh lebih banyak dibanding outlier. Model bisa saja terlihat akurat walaupun gagal mendeteksi outlier.

2. Precision

Precision mengukur seberapa tepat model dalam mendeteksi data yang dianggap sebagai outlier.

$$Precision = \frac{TP}{TP+FP}$$

Dalam konteks ini:

- TP = outlier yang berhasil terdeteksi dengan benar
- FP = data normal yang salah dianggap sebagai outlier

Precision penting agar model tidak terlalu banyak salah menghapus data normal.

3. Recall (Sensitivity)

Recall mengukur kemampuan model dalam menemukan seluruh data outlier yang ada.

$$Recall = \frac{TP}{TP+FN}$$

- FN = outlier yang tidak terdeteksi

Recall sangat penting dalam penelitian ini karena tujuan utama adalah mendeteksi sebanyak mungkin outlier.

4. F1-Score

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Metrik ini menjadi yang paling utama dalam penelitian outlier karena:

- Data tidak seimbang (outlier sedikit)
- Harus menjaga keseimbangan antara tidak salah hapus data normal (precision) dan tidak melewatkan outlier (recall)

Metrik ini menjadi yang paling penting pada kasus outlier karena data bersifat tidak seimbang.

5. AUC-ROC

AUC-ROC digunakan untuk mengukur kemampuan model dalam membedakan data normal dan outlier. Nilai AUC berkisar antara 0 sampai 1, di mana semakin mendekati 1 berarti model semakin baik dalam membedakan kedua kelas tersebut. Nilai AUC berada antara 0 sampai 1:

- Mendekati 1 → model sangat baik dalam membedakan outlier
- Mendekati 0.5 → model tidak lebih baik dari tebakan acak

Metrik ini membantu melihat performa model secara keseluruhan, terutama setelah dilakukan preprocessing.

6. Confusion Matrix

Confusion Matrix digunakan untuk melihat hasil prediksi secara detail, yang terdiri dari TP, TN, FP, dan FN. Dari matriks ini dapat diketahui apakah model terlalu banyak salah mendeteksi outlier atau justru melewatkan outlier yang ada.

Komponennya:

- TP (True Positive): outlier yang terdeteksi dengan benar
- TN (True Negative): data normal yang dikenali dengan benar
- FP (False Positive): data normal yang salah dianggap outlier
- FN (False Negative): outlier yang tidak terdeteksi

2.5 Penelitian Terkait

2.5.1 Outlier Detection Performance of a Modified Z-Score Method in Time-Series RSS Observation With Hybrid Scale Estimators

Pada penelitian Abdulmalik Shehu Yaro dkk (2024) untuk mendeteksi outlier pada time-series *Received Signal Strength* (RSS) di lingkungan sensor nirkabel, peneliti menggunakan metode Z-Score yang dimodifikasi dengan berbagai varian hybrid scale estimator (MAD dan Sn) [8]. Dataset yang digunakan oleh peneliti merupakan data time-series yang diambil dari lingkungan IoT dengan distribusi yang bervariasi antara simetris dan asimetris. Hasil penelitian ini menunjukkan bahwa kinerja dari Modified Z-Score sangat dipengaruhi oleh pemilihan scale estimator yang digunakan [8]. Perbedaan dengan penelitian ini terletak pada beberapa aspek, yaitu domain data (sensor RSS vs data gelombang laut oseanografi), metode deteksi yang digunakan hanya bersifat univariat tanpa membandingkan dari berbagai kategori, seperti *Interquartile Range* (IQR), dan tidak adanya evaluasi dampak treatment terhadap kinerja model klasifikasi hilir.

2.5.2 Research on the effectiveness of different outlier detection methods in common data distribution types

Pada penelitian Song dan Xia (2024), peneliti melakukan studi komparatif terhadap lima metode deteksi outlier, yaitu Z-Score, IQR, DBSCAN, Isolation Forest, dan Random Forest, pada data dari sembilan jenis distribusi probabilitas kontinu dan diskrit [12]. Berdasarkan karakteristik distribusi data, penelitian ini memberikan gambaran menyeluruh tentang efektivitas dari masing-masing metode yang digunakan. Menurut peneliti terdahulu, tidak ada satu metode yang benar-benar cocok untuk semua jenis distribusi data. Setiap metode memiliki keunggulan dalam kondisi distribusi tertentu [12]. Perbedaan dengan penelitian ini berada pada konteks data yang digunakan, penelitian ini menggunakan data sintetis dari distribusi matematis tanpa konteks domain nyata. Selain itu, pada penelitian ini juga dilakukan evaluasi tentang pengaruh *treatment outlier* terhadap kinerja model klasifikasi pada data nyata, seperti data gelombang laut oseanografi.

2.5.3 An Outliers Detection and Elimination Framework in Classification Task of Data Mining

Pada penelitian terdahulu, Sanjeev Kumar Dash dkk (2023) mengusulkan framework deteksi dan eliminasi outlier dalam tugas klasifikasi data mining, dengan mengevaluasi dampak langsung dari proses eliminasi outlier terhadap kinerja model klasifikasi melalui berbagai metrik evaluasi. Penelitian ini menekankan bahwa metode treatment outlier yang dipilih berdampak signifikan pada hasil klasifikasi, dan penelitian ini menyarankan untuk menggunakan metrik evaluasi yang luas untuk menilai efektivitas treatment [13]. Perbedaan dengan penelitian ini adalah penelitian ini menggunakan dataset oseanografi real-world berbasis time-series dengan label kondisi laut berdasarkan standar internasional Douglas Sea Scale. Selain itu, penelitian ini memasukkan pendekatan multivariat yang sebelumnya tidak dipertimbangkan dalam penelitian sebelumnya.

2.5.4 Isolation Forest: An Algorithm for Anomaly Detection

Pada penelitian Liu, Ting, dan Zhou (2008), peneliti memperkenalkan algoritma deteksi anomali bernama Isolation Forest yang bekerja berdasarkan prinsip isolasi data menggunakan struktur pohon keputusan secara acak. Dataset yang digunakan merupakan kumpulan dataset benchmark sintetis dan nyata dari berbagai domain, termasuk data dengan distribusi yang bervariasi dan proporsi anomali yang berbeda-beda. Hasil penelitian menunjukkan bahwa Isolation Forest mampu mendeteksi anomali secara efektif tanpa memerlukan asumsi distribusi data tertentu, dengan kompleksitas waktu yang linier serta konsumsi memori yang rendah sehingga efisien untuk dataset berskala besar [3]. Perbedaan dengan penelitian ini terletak pada konteks data yang digunakan, yakni data oseanografi berbasis time-series ketinggian gelombang laut yang bersifat dinamis dan fluktuatif. Selain itu, penelitian ini membandingkan Isolation Forest secara langsung dengan pendekatan statistik robust yaitu Modified Z-Score untuk menilai efektivitas masing-masing metode dalam meningkatkan kualitas data pada domain kelautan.

2.5.5 Australian Ocean Surface Waves Dataset from SAR

Pada penelitian Khan, Hemer, Echevarria, dan King (2024), peneliti mengembangkan dataset gelombang laut permukaan regional dari satelit Synthetic

Aperture Radar (SAR) Sentinel-1 A dan B untuk kawasan Australia dan sekitarnya. Dataset yang digunakan bersumber dari produk Level-2 OCN Sentinel-1 yang disediakan oleh European Space Agency dan diperoleh melalui Copernicus Australasia regional data hub, mencakup data time-series dari Juli 2015 hingga Mei 2021. Metode yang digunakan adalah prosedur Quality Assurance and Control (QA/QC) yang meliputi homogenisasi struktur file NetCDF, penanganan inkonsistensi variabel koordinat, penghapusan pengukuran yang salah di area pesisir, serta penambahan variabel auxilier seperti kedalaman dasar laut dan jarak ke garis pantai. Hasil penelitian menunjukkan bahwa data gelombang laut dari sensor SAR maupun sensor berbasis stasiun memiliki inkonsistensi dan noise yang signifikan akibat perbedaan versi pemrosesan instrumen, sehingga tahap pembersihan dan kontrol kualitas data merupakan langkah yang sangat krusial sebelum data dapat digunakan untuk analisis lebih lanjut. Penelitian ini memperkuat relevansi penelitian yang akan dilakukan, karena Gold Coast City Wave Dataset 2014-2024 yang digunakan juga merupakan data time-series ketinggian gelombang laut dari kawasan Australia yang berpotensi mengandung noise dan outlier serupa. Perbedaan dengan penelitian ini terletak pada pendekatan yang digunakan; apabila Khan et al. (2024) berfokus pada homogenisasi dan kontrol kualitas berbasis prosedur teknis satelit, penelitian ini berfokus pada deteksi dan penanganan outlier menggunakan metode statistik robust (Modified Z-Score) dan machine learning (Isolation Forest) untuk meningkatkan kualitas data sebelum tahap pemodelan.


BAB III

METODOLOGI PENELITIAN

3.1 Alur Penelitian

Penelitian ini dilakukan berdasarkan tahapan yang sistematis agar proses deteksi outlier dapat dievaluasi dan dibandingkan dengan baik. Alur penelitian ini mengikuti tahapan dalam data mining, khususnya pada tahap preprocessing yang fokus pada mendeteksi dan menangani outlier pada data time-series ketinggian gelombang laut.

Secara umum, penelitian ini terdiri dari tujuh tahap utama, yaitu pengumpulan data, eksplorasi data, pembagian data menjadi training dan testing, preprocessing pada data training, pelatihan model, evaluasi menggunakan data testing, serta analisis hasil.



Gambar 3.1 Alur Penelitian

1. Pengumpulan Data

Pada tahap awal, dilakukan pengumpulan data yang akan digunakan dalam penelitian. Data yang dipakai berasal dari dataset Australian Ocean Surface Waves from SAR (Level-2P) yang diperoleh melalui Australian Ocean Data Network (AODN). Dataset ini berisi informasi ketinggian gelombang laut atau Significant Wave Height (Hsig) yang diambil dari sensor satelit.

Data tersebut memiliki bentuk time-series atau deret waktu, sehingga nilainya bisa berubah-ubah tergantung kondisi lingkungan. Selain itu, data ini juga memiliki kemungkinan mengandung noise dan outlier karena dipengaruhi oleh faktor alam. Jumlah data yang digunakan sekitar 697 baris dengan 10 fitur, sehingga cukup untuk dianalisis lebih lanjut dalam penelitian ini.

2. Eksplorasi Data (Exploratory Data Analysis / EDA)

Setelah data dikumpulkan, langkah berikutnya adalah melakukan eksplorasi data atau EDA untuk memahami isi dataset. Pada tahap ini dilakukan analisis statistik

seperti mencari nilai rata-rata, median, dan standar deviasi. Selain itu, data juga divisualisasikan dalam bentuk grafik time-series untuk melihat pola pergerakan gelombang laut.

Melalui proses ini, dapat diidentifikasi apakah terdapat tren tertentu, pola pergerakan, atau fluktuasi ekstrem pada data. Selain itu, tahap ini juga membantu dalam mendeteksi secara awal adanya outlier yang mungkin dapat mempengaruhi hasil analisis.

3. Train-Test Split

Selanjutnya, data dibagi menjadi dua bagian, yaitu data training dan data testing. Pembagian ini dilakukan berdasarkan urutan waktu agar pola asli data tetap terjaga dan tidak tercampur.

Biasanya digunakan perbandingan 80% untuk data training dan 20% untuk data testing. Tujuan dari pembagian ini adalah agar model dapat dilatih menggunakan sebagian data, lalu diuji menggunakan data lain yang belum pernah dilihat sebelumnya. Hal ini penting untuk menghindari overfitting dan memastikan model bekerja dengan baik pada data baru.

4. Preprocessing (Train)

Tahap preprocessing dilakukan pada data training untuk memperbaiki kualitas data sebelum digunakan dalam model. Pada tahap ini dilakukan beberapa proses seperti menangani data yang hilang (missing values) dan mendeteksi outlier.

Metode yang digunakan untuk mendeteksi outlier adalah Modified Z-Score dan Isolation Forest. Modified Z-Score digunakan karena lebih tahan terhadap data yang tidak normal, sedangkan Isolation Forest digunakan karena dapat mendeteksi outlier tanpa harus mengikuti distribusi tertentu. Setelah outlier ditemukan, dilakukan penanganan seperti menghapus atau menyesuaikan nilainya. Tahap ini sangat penting karena berpengaruh langsung terhadap kualitas hasil model.

5. Training Model

Pada tahap ini, model mulai dilatih menggunakan data training yang sudah diproses sebelumnya. Dua metode yang digunakan adalah Modified Z-Score dan Isolation Forest.

Model akan belajar mengenali pola data normal, sehingga nantinya bisa membedakan mana data yang termasuk normal dan mana yang termasuk outlier. Dengan membandingkan dua metode ini, peneliti dapat melihat metode mana yang lebih efektif dalam mendeteksi data yang menyimpang.

6. Evaluasi (Test Asli)

Setelah model dilatih, dilakukan evaluasi menggunakan data testing yang belum pernah digunakan sebelumnya. Tujuan dari evaluasi ini adalah untuk mengukur seberapa baik model dalam mendeteksi outlier.

Beberapa metrik yang digunakan antara lain accuracy, precision, recall, F1-score, AUC-ROC, dan confusion matrix. Metrik-metrik ini dipilih karena cocok digunakan pada data yang tidak seimbang, di mana jumlah outlier biasanya lebih sedikit dibanding data normal. Hasil evaluasi ini akan menunjukkan performa masing-masing metode.

7. Analisis Hasil

Tahap terakhir adalah melakukan analisis terhadap hasil yang diperoleh dari seluruh proses penelitian. Pada tahap ini, dilakukan perbandingan antara metode Modified Z-Score dan Isolation Forest untuk melihat mana yang lebih baik.

Selain itu, juga dianalisis apakah metode tersebut mampu menghilangkan noise tanpa merusak pola asli data. Perubahan distribusi data sebelum dan sesudah preprocessing juga diperhatikan, termasuk apakah nilai ekstrem yang tidak wajar berhasil dikurangi. Dari hasil analisis ini, dapat ditentukan metode terbaik untuk meningkatkan kualitas data ketinggian gelombang laut.

3.2 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini adalah Australian Ocean surface waves from SAR (Level-2P) yang diperoleh dari Australian Ocean Data Network (AODN) melalui repositori Copernicus Australasia (URL:[DATASET](#)). Dataset asli berupa file NetCDF yang kemudian dilakukan resampling per 3 jam dan difilter pada rentang waktu Januari hingga April 2022. Dataset memiliki karakteristik sebagai berikut:

- Jumlah sampel: 697 observasi (setelah resampling dan filtering missing values)

- Jumlah fitur: 7 fitur numerik (EKTH, DIRECTION, HS_PART, WP_PART, WSPD_ECMWF, WDIR_ECMWF, BOT_DEPTH, DIST2COAST) ditambah TIME
- Variabel target: Outlier_Label — 0 = Inlier (Data Normal), 1 = Outlier (dibuat berdasarkan kuantil ke-90 dari HS_PART)
- Distribusi kelas: Kelas 0 (Inlier) $\approx$ 90%, Kelas 1 (Outlier) $\approx$ 10%, dengan data training 557 sampel dan data testing 140 sampel
- Missing Values: Area daratan telah di-masking menggunakan grid batimetri; observasi dengan missing value telah dihapus (dropna) sebelum analisis.

Tabel 2. Deskripsi Fitur Dataset AODN

No	Nama Fitur	Tipe	Deskripsi
1	TIME	Numerik	Waktu observasi berdasarkan titik tengah pengukuran
2	EKTH	Numerik	Spektrum kepadatan gelombang laut
3	DIRECTION	Numerik	Arah rambat gelombang permukaan laut
4	HS_PART	Numerik	Tinggi gelombang signifikan (dasar pembuatan label)
5	WP_PART	Numerik	Panjang gelombang pada saat puncak spektrum
6	WSPD_ECMWF	Numerik	Kecepatan angin dari model cuaca ECMWF
7	WDIR_ECMWF	Numerik	Arah angin dari model cuaca ECMWF
8	BOT_DEPTH	Numerik	Kedalaman dasar laut di titik observasi

9	DIST2COA ST	Numerik	Jarak terdekat dari titik pengukuran ke garis pantai
10	Outlier_Label	Biner	Variabel target: 0 = Inlier, 1 = Outlier

3.3 Prosedur Eksperimen

3.3.1 Pembagian Data (Train-Test Split)

Dalam tahapan eksperimen ini, dataset ketinggian gelombang laut yang berjumlah sekitar 697 baris akan dibagi menjadi dua bagian utama, yaitu data training dan data testing. Karena data yang diolah memiliki karakteristik time-series (deret waktu), proses pembagiannya tidak boleh dilakukan secara acak (random split). Pengacakan data dapat merusak pola urutan waktu observasi dan berisiko memicu data leakage, yaitu kondisi di mana data pengujian (testing) ikut terpakai saat proses pelatihan model.

Oleh karena itu, pembagian data dilakukan secara berurutan (sequential time-series split). Proporsi pembagian yang diterapkan adalah 80% untuk data training dan 20% untuk data testing. Dengan demikian, diperkirakan sekitar 557 baris data awal berdasarkan urutan waktu akan digunakan sebagai data training, sedangkan sisa 140 baris observasi terakhir dialokasikan untuk data testing.

Data training ini nantinya berfungsi sebagai dasar bagi metode Modified Z-Score dan algoritma Isolation Forest untuk memodelkan pola distribusi gelombang laut yang normal dan menentukan ambang batas kemunculan anomali. Sementara itu, data testing akan diisolasi dan murni digunakan pada tahap evaluasi untuk menguji objektivitas serta performa kedua metode tersebut dalam mendeteksi outlier pada observasi baru yang belum pernah "dilihat" sebelumnya.

3.3.2 Metode yang Digunakan

Penelitian ini menggunakan dua metode utama untuk proses deteksi outlier, yang mewakili pendekatan statistik dan machine learning. Berikut adalah penjelasan penerapan masing-masing metode:

1. Modified Z-Score

Metode ini diterapkan sebagai pendekatan statistik yang robust untuk mendeteksi outlier. Modified Z-Score merupakan pengembangan dari Z-Score standar yang menggantikan penggunaan mean dan standar deviasi dengan median dan Median Absolute Deviation (MAD). Penggunaan median dipilih karena nilainya lebih stabil dan tidak mudah terpengaruh oleh keberadaan nilai ekstrem. Pada implementasinya, sebuah titik data akan diklasifikasikan sebagai outlier apabila nilai absolut perhitungannya melewati ambang batas (threshold) yang telah ditetapkan, yaitu $|Mi| > 3.5$.

2. Isolation Forest

Sebagai perbandingan dari sisi machine learning, metode Isolation Forest digunakan karena algoritma ini dirancang khusus untuk deteksi anomali. Isolation Forest bekerja dengan prinsip mengisolasi data melalui pembentukan sekumpulan pohon keputusan (decision tree) secara acak. Konsep utamanya adalah data outlier cenderung memiliki sedikit tetangga dan berada jauh dari kumpulan data normal, sehingga akan lebih cepat terisolasi pada kedalaman pohon yang lebih dangkal. Pada penerapannya, parameter contamination akan diatur sesuai dengan estimasi rasio anomali pada data gelombang laut tersebut untuk membatasi jumlah data yang dipotong.

3.3.3 Algoritma Klasifikasi

Setelah tahapan preprocessing dan penanganan outlier selesai dilakukan, penelitian ini menggunakan algoritma klasifikasi Random Forest Classifier (Breiman, 2001) untuk menguji dan mengevaluasi kualitas data yang telah dibersihkan. Implementasi algoritma ini dilakukan menggunakan pustaka scikit-learn dengan menggunakan pengaturan parameter bawaan (default), yaitu jumlah pohon keputusan pembentuk model ($n_estimators$) sebanyak 100, serta penentuan nilai $random_state=42$ untuk memastikan konsistensi dan agar hasil eksperimen dapat direproduksi (reproducible).

Pemilihan Random Forest sebagai classifier dalam penelitian ini didasarkan pada beberapa keunggulan utama yang sangat sesuai dengan karakteristik dataset deret waktu gelombang laut, antara lain:

- Lebih tahan terhadap overfitting: Random Forest merupakan algoritma ensemble yang menerapkan konsep bagging. Model ini bekerja dengan cara

membangun banyak decision tree (pohon keputusan), lalu mengambil hasil akhirnya berdasarkan suara terbanyak (majority voting). Penggabungan banyak pohon ini membuat model lebih stabil dan terhindar dari overfitting (terlalu menghafal data training), yang mana sering menjadi kelemahan jika hanya menggunakan satu decision tree tunggal.

- Tidak memerlukan feature scaling (penyesuaian skala fitur): Karena Random Forest adalah model yang berbasis pohon (tree-based), proses pemisahan datanya tidak dihitung berdasarkan jarak matematis antar observasi. Oleh karena itu, nilai fitur-fitur kelautan yang satuan dan rentangnya berbeda-beda dapat langsung dimasukkan ke dalam model tanpa harus melewati tahapan normalisasi atau standarisasi terlebih dahulu.
- Mampu menangani pola data non-linear: Karakteristik data kelautan, seperti ketinggian gelombang, kecepatan angin, dan kedalaman laut, sering kali memiliki korelasi dan pola distribusi yang sangat kompleks dan tidak beraturan. Algoritma Random Forest sangat efisien dalam menangkap dan memetakan hubungan non-linear maupun interaksi fitur tingkat tinggi yang rumit tanpa memerlukan transformasi matematis tambahan pada data tersebut.

3.3.4 Metrik Evaluasi

Untuk mengukur performa model klasifikasi pada masing-masing skenario treatment, penelitian ini menggunakan lima metrik evaluasi berikut:

1. Accuracy: Proporsi prediksi yang benar secara keseluruhan dari seluruh data uji. Namun, metrik ini kurang informatif pada data yang tidak seimbang karena model bisa terlihat akurat walaupun gagal mendeteksi kelas outlier (minoritas).
2. Precision (macro): Rata-rata precision per kelas yang mengukur seberapa tepat model dalam memprediksi data sebagai outlier maupun inlier, sehingga model tidak terlalu banyak salah dalam menghapus data normal.
3. Recall (macro): Rata-rata recall per kelas yang mengukur kemampuan model dalam menemukan seluruh data yang sebenarnya termasuk dalam tiap kelas. Hal ini penting, khususnya untuk mendeteksi kelas minoritas (outlier) agar tidak ada data yang terlewat.

4. F1-Score (macro): Harmonic mean dari precision dan recall yang menjadi metrik utama dalam perbandingan antar metode, karena menyeimbangkan keduanya sekaligus lebih representatif untuk data yang tidak seimbang (imbalanced).
5. AUC-ROC: Mengukur kemampuan model dalam membedakan antar kelas secara keseluruhan. Nilai mendekati 1 menunjukkan model sangat baik dalam membedakan outlier dari inlier, sedangkan nilai mendekati 0,5 menunjukkan performa tidak lebih baik dari tebakan acak.


Metrik utama yang digunakan untuk menentukan metode terbaik adalah F1-Score karena menyeimbangkan precision dan recall, serta lebih informatif dibandingkan accuracy untuk data yang tidak seimbang (imbalanced). Seluruh evaluasi dilakukan pada test set asli yang tidak mengalami preprocessing outlier apapun.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Eksplorasi Data (EDA)

4.1.1 Gambaran Umum Dataset



Gambar 4.1 Gambaran Umum Dataset

Gambar 4.1 menyajikan distribusi fitur numerik dari dataset menggunakan visualisasi boxplot. Melalui grafik ini, dapat diamati rentang data dan keberadaan pencilan (outlier) pada masing-masing fitur. Fitur seperti BOT_DEPTH dan DIST2COAST memiliki sebaran yang lebar dan menunjukkan titik-titik di luar batas kumis (whisker), yang menandakan adanya potensi outlier ekstrem yang perlu ditangani sebelum masuk ke tahap pemodelan.

Tabel 3. Tabel Distribusi Kelas Target (Data Training)

Distribusi Kelas Target	Value
0 (Inliner) Training	89.9% = 557
1 (Outlier) Testing	10.1% = 140

Dataset yang digunakan dalam penelitian ini merupakan data time-series ketinggian gelombang laut hasil resampling per 3 jam dari dataset AODN periode Januari hingga April 2022. Setelah proses pembersihan awal (penghapusan missing


values dan duplikasi), dataset terdiri dari 697 baris observasi dengan 7 fitur numerik yang relevan. Variabel target `Outlier_Label` dibuat berdasarkan kuantil ke-90 dari fitur `HS_PART`, di mana observasi dengan nilai `HS_PART` di atas ambang batas tersebut dikategorikan sebagai outlier (label 1), sedangkan sisanya dikategorikan sebagai inlier (label 0).

Secara statistik deskriptif, fitur-fitur dalam dataset menunjukkan karakteristik yang beragam. Fitur `DIRECTION` memiliki rentang nilai yang lebar karena merupakan representasi arah dalam derajat ($0-360^\circ$). Fitur `BOT_DEPTH` dan `DIST2COAST` juga memiliki variasi yang cukup tinggi mengingat data diambil dari berbagai titik observasi dengan karakteristik geografis yang berbeda-beda. Sementara itu, fitur `HS_PART` sebagai fitur utama penelitian menunjukkan distribusi yang cenderung right-skewed, yang mengindikasikan adanya beberapa observasi dengan nilai gelombang yang jauh lebih tinggi dari rata-rata.

4.1.2 Distribusi Fitur


Berdasarkan visualisasi boxplot fitur numerik pada data training, terlihat bahwa beberapa fitur memiliki titik-titik pencilan yang cukup jelas. Fitur `DIRECTION` menunjukkan distribusi yang relatif merata namun dengan beberapa titik ekstrem di kedua ujung rentang. Fitur `BOT_DEPTH` menunjukkan sebaran yang lebar dengan potensi outlier di sisi atas, mencerminkan variasi kedalaman laut di berbagai titik pengamatan. Fitur `DIST2COAST` juga menunjukkan pola serupa, yaitu mayoritas observasi berada di jarak yang relatif dekat ke pantai, namun terdapat beberapa titik yang jaraknya jauh lebih besar dari yang lain.

Secara umum, distribusi fitur-fitur tersebut menunjukkan bahwa data gelombang laut memang mengandung potensi outlier yang perlu ditangani sebelum proses pemodelan. Hal ini konsisten dengan temuan Khan et al. (2024) yang menyebutkan bahwa data SAR kerap mengandung nilai tidak konsisten akibat faktor sensor dan kondisi lingkungan. Gambar 4.2 hingga Gambar 4.4 memperlihatkan perbandingan distribusi data pada salah satu fitur (`EKTH`) sebelum dan sesudah dilakukan penanganan outlier.




Gambar 4.2 Data Sebelum Treatment

Pada Gambar 4.2, distribusi awal data cenderung condong ke kanan dengan ekor grafik yang panjang, mengindikasikan keberadaan nilai-nilai yang ekstrem.



Gambar 4.3 Data Setelah Treatment (Mod Z-Score)



Gambar 4.4 Data Setelah Treatment (Isolation Forest)

Setelah dilakukan penghapusan data (removal) menggunakan metode Modified Z-Score (Gambar 4.3) dan Isolation Forest (Gambar 4.4), ekor distribusi tersebut menjadi lebih pendek. Penurunan nilai standar deviasi pada grafik sesudah treatment merepresentasikan bahwa persebaran data telah menjadi lebih terpusat dan gangguan (noise) akibat nilai anomali telah berhasil dikurangi.

4.1.3 Distribusi Kelas Target

Distribusi kelas target pada dataset menunjukkan ketidakseimbangan yang cukup signifikan. Dari total 697 observasi, sekitar 90% merupakan inlier (label 0) dan 10% merupakan outlier (label 1). Pada data training yang terdiri dari 557 sampel, terdapat 501 inlier (89,9%) dan 56 outlier (10,1%). Sementara itu, data testing terdiri dari 140 sampel dengan proporsi serupa. Ketidakseimbangan kelas ini merupakan salah satu alasan mengapa F1-Score dipilih sebagai metrik utama evaluasi, karena metrik ini lebih representatif dibandingkan accuracy pada kondisi data yang tidak seimbang (imbalanced).

4.2 Outlier Detection

4.2.1 Deteksi Outlier—Boxplot Visual

Deteksi awal outlier dilakukan secara visual menggunakan boxplot pada fitur-fitur numerik data training. Boxplot menampilkan distribusi data secara ringkas melalui kuartil dan menandai titik-titik yang berada di luar batas interquartile range (IQR). Dari visualisasi yang dihasilkan, terlihat bahwa beberapa fitur memiliki titik outlier yang cukup kentara, terutama pada fitur BOT_DEPTH dan DIST2COAST yang menunjukkan titik merah (outlier) di luar whisker boxplot. Fitur DIRECTION juga menunjukkan beberapa titik ekstrem yang perlu diperhatikan.

Temuan dari boxplot ini memperkuat dugaan awal bahwa data AODN memang mengandung outlier yang berpotensi mengganggu proses pembelajaran model. Hal ini menjadi dasar dilakukannya deteksi outlier menggunakan dua metode yang lebih formal dan terukur, yaitu Modified Z-Score dan Isolation Forest.

4.2.2 Deteksi Outlier—2 Metode + Tabel Ringkasan

Setelah dilakukan deteksi visual, outlier diidentifikasi secara kuantitatif menggunakan Modified Z-Score dan Isolation Forest pada data training. Modified Z-Score diterapkan secara multivariat, di mana sebuah baris dianggap sebagai outlier apabila setidaknya satu fiturnya memiliki $|Mi| > 3.5$. Sementara itu, Isolation Forest menggunakan parameter contamination = 0.05, yang artinya sekitar 5% data training diprediksi sebagai outlier. Tabel 3 merangkum hasil deteksi dari kedua metode.

Tabel 4. Jumlah Outlier per Metode Deteksi pada Data Training

Metode	Outlier Terdeteksi	Persentase (%)
Modified Z-Score ($ Mi > 3.5$)	27	4,85%
Isolation Forest (contamination=0.05)	28	5,03%

Berdasarkan Tabel 4, kedua metode menghasilkan jumlah outlier yang relatif serupa, yaitu Modified Z-Score mendeteksi 27 outlier (4,85%) dan Isolation Forest mendeteksi 28 outlier (5,03%). Meskipun jumlahnya hampir sama, belum tentu kedua metode mendeteksi outlier yang sama persis. Modified Z-Score mengidentifikasi outlier berdasarkan jarak absolut nilai dari median fitur yang diukur melalui MAD, sehingga lebih sensitif terhadap nilai ekstrem pada fitur-fitur tertentu. Isolation Forest, di sisi lain, mendeteksi outlier berdasarkan kemudahan isolasi dalam ruang multidimensi, sehingga mampu menangkap pola anomali yang mungkin tidak terlihat jika dilihat dari satu fitur saja. Perbedaan pendekatan ini berpotensi menghasilkan kumpulan outlier yang sedikit berbeda antar metode.

4.3 Treatment

4.3.1 Treatment—Strategi

Setelah outlier berhasil diidentifikasi oleh masing-masing metode, strategi treatment yang diterapkan adalah removal, yaitu menghapus seluruh baris data yang teridentifikasi sebagai outlier dari data training. Pemilihan strategi removal dilakukan dengan pertimbangan bahwa data AODN yang bersumber dari sensor SAR berpotensi mengandung erroneous outlier akibat gangguan sinyal, sehingga penghapusan lebih aman dibandingkan strategi lain seperti capping atau transformasi yang dapat memperkenalkan bias.

Setelah treatment, data training yang digunakan untuk melatih model berkurang. Untuk skenario Removal Modified Z-Score, data training berkurang dari 557 menjadi 530 sampel (27 baris dihapus). Untuk skenario Removal Isolation Forest, data training berkurang dari 557 menjadi 529 sampel (28 baris dihapus). Penting untuk dicatat bahwa data testing sama sekali tidak disentuh dalam proses deteksi maupun treatment, sehingga evaluasi model dilakukan pada test set asli yang bersih dan representatif.

4.3.2 Visualisasi Before vs After Treatment

Visualisasi perubahan distribusi data sebelum dan sesudah treatment dilakukan pada salah satu fitur numerik. Berdasarkan Gambar 2, terlihat adanya perubahan pada distribusi data setelah proses removal. Distribusi data sebelum treatment menunjukkan

adanya ekor di sisi kanan yang mengindikasikan keberadaan nilai-nilai ekstrem (outlier). Setelah diterapkan removal berbasis Modified Z-Score, ekor distribusi tersebut terlihat lebih pendek, menandakan bahwa nilai-nilai ekstrem telah berhasil dihapus. Hal serupa juga terlihat pada distribusi setelah Removal Isolation Forest.

Perubahan nilai mean dan standar deviasi setelah treatment juga menunjukkan perbaikan kualitas data. Nilai standar deviasi yang sedikit menurun setelah removal mengindikasikan bahwa distribusi data menjadi lebih terkonsentrasi di sekitar nilai sentral, yang artinya noise dari outlier telah berhasil dikurangi. Meskipun demikian, perubahan distribusi ini tidak terlalu drastis, yang sesuai dengan jumlah outlier yang relatif sedikit (kurang dari 6% dari data training).

4.3.3 Evaluasi Dampak Treatment terhadap Klasifikasi

Evaluasi dampak treatment dilakukan dengan melatih model Random Forest pada masing-masing skenario data training, kemudian mengevaluasinya pada test set asli. Tiga skenario yang dibandingkan adalah: Baseline (tanpa treatment), Removal Modified Z-Score, dan Removal Isolation Forest. Hasil perbandingan performa dapat dilihat pada Tabel 5 dan Gambar 3.

4.4 Hasil Perbandingan Metode


4.4.1 Tabel Perbandingan Performa

Tabel 5. Perbandingan Performa Klasifikasi pada Test Set Asli

Model (Strategi Treatment)	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Baseline (Tanpa Treatment)	0,9214	0,7841	0,7659	0,7746	0,9535
Removal — Modified Z-Score	0,9286	0,8099	0,7698	0,7880	0,9657
Removal — Isolation Forest	0,9214	0,7841	0,7659	0,7746	0,9646


Berdasarkan Tabel 5, metode Removal berbasis Modified Z-Score menghasilkan performa terbaik dengan F1-Score sebesar 0,7880 dan AUC-ROC sebesar 0,9657. Dibandingkan dengan Baseline yang tidak menerapkan treatment apapun, metode ini berhasil meningkatkan F1-Score sebesar 0,0134 atau sekitar 1,73% dan AUC-ROC sebesar 0,0122. Sementara itu, Removal Isolation Forest tidak menunjukkan peningkatan pada metrik Accuracy, Precision, Recall, dan F1-Score dibandingkan Baseline, meskipun AUC-ROC-nya sedikit lebih tinggi (0,9646 vs 0,9535).

4.4.2 Visualisasi Perbandingan




Gambar 4.5 Visualisasi Perbandingan F1 - Score

Gambar 4.5 menampilkan perbandingan F1-Score antar skenario dalam bentuk bar chart. Terlihat dengan jelas bahwa Removal Modified Z-Score memiliki batang yang paling tinggi dengan nilai 0,7880, sedangkan Baseline dan Removal Isolation Forest berada pada nilai yang sama, yaitu 0,7746. Perbedaan ini meskipun tidak sangat besar, tetap signifikan dalam konteks peningkatan kualitas model, mengingat perbedaan tersebut murni berasal dari perbaikan kualitas data training.




Gambar 4.6 Visualisasi Perbandingan ROC

Gambar 4.6 menampilkan kurva ROC dari ketiga skenario. Ketiga kurva berada di area atas grafik dengan nilai AUC yang tinggi (di atas 0,95), yang menunjukkan bahwa model Random Forest secara keseluruhan memiliki kemampuan diskriminasi yang baik pada dataset ini. Kurva Removal Modified Z-Score berada sedikit di atas dua kurva lainnya, mengkonfirmasi superioritas metode tersebut dalam meningkatkan performa model.




Gambar 4.7 Confusion Matrix pada Data Sebelum Treatment

Sebagai konteks awal pada matriks kebingungan (confusion matrix) ini, label 0 merepresentasikan data normal (inlier), sedangkan label 1 merepresentasikan data anomali (outlier). Gambar 4.7 menunjukkan hasil prediksi dari model yang dilatih menggunakan data awal tanpa penanganan outlier (baseline). Dari total 140 data pengujian, model berhasil memprediksi 129 data dengan tepat, yang mencakup 121 data normal dan 8 data outlier. Namun, masih terdapat 11 kesalahan prediksi, di mana 5 data normal keliru ditebak sebagai outlier (False Positive), dan 6 data outlier luput dari deteksi karena diprediksi sebagai data normal (False Negative).



Gambar 4.8 Confusion Matrix pada Data Setelah Treatment (Mod Z-Score)

Gambar 4.8 merepresentasikan kinerja prediksi model setelah data latihnya dibersihkan menggunakan metode Modified Z-Score. Hasilnya menunjukkan perbaikan akurasi dengan total 130 tebakan yang tepat, terdiri dari 122 data normal dan 8 data outlier. Terdapat peningkatan pengenalan data normal sebanyak satu angka dibandingkan model baseline. Kesalahan prediksi pada data normal yang keliru dianggap outlier (False Positive) berhasil ditekan menjadi 4 data saja, sementara jumlah outlier yang gagal terdeteksi (False Negative) tetap berada di angka 6. Penurunan angka kesalahan (False Positive) inilah yang menjadi faktor utama mengapa skenario ini memiliki skor Presisi dan F1-Score yang paling tinggi.



Gambar 4.9 Confusion Matrix pada Data Setelah Treatment (Isolation Forest)

Gambar 4.9 menampilkan matriks kebingungan dari model yang dilatih setelah data ditangani menggunakan Isolation Forest. Rincian prediksinya menunjukkan 129 tebakan benar (121 data normal dan 8 data outlier) serta 11 tebakan salah (5 False Positive dan 6 False Negative). Distribusi angka pada skenario ini bernilai sama persis dengan skenario baseline. Hasil ini secara langsung mengonfirmasi mengapa skor metrik evaluasi seperti Akurasi, Presisi, Recall, dan F1-Score untuk metode Isolation Forest tidak mengalami perubahan sama sekali pada tabel perbandingan performa.

4.5 Pembahasan

Secara keseluruhan, hasil eksperimen menunjukkan bahwa penerapan tahap preprocessing untuk menangani outlier memberikan dampak positif terhadap performa model klasifikasi, meskipun besaran peningkatannya bervariasi bergantung pada metode yang digunakan. Metode penghapusan (removal) berbasis Modified Z-Score terbukti lebih efektif dibandingkan Isolation Forest dalam meningkatkan kualitas data latih dan performa model.

Keunggulan Modified Z-Score dalam penelitian ini dapat dijelaskan dari karakteristik data yang digunakan. Data gelombang laut dari sensor SAR memiliki distribusi yang cenderung tidak normal dan condong ke kanan (right-skewed), terutama pada fitur HS_PART. Dalam kondisi seperti ini, Modified Z-Score yang menggunakan nilai

median dan MAD menjadi lebih presisi dalam mendeteksi outlier dibandingkan metode berbasis rata-rata (mean) seperti Z-Score standar, karena penghitungan batasannya (threshold) tidak ikut terpengaruh oleh keberadaan nilai ekstrem itu sendiri (Iglewicz & Hoaglin, 1993). Dengan menghapus 27 titik data yang paling menyimpang, metode ini mampu mengurangi noise utama tanpa berisiko menghilangkan terlalu banyak informasi.

Keberhasilan Modified Z-Score tersebut juga tervalidasi secara empiris melalui metrik confusion matrix. Metode ini mampu menekan angka False Positive pada tahap klasifikasi, yaitu menurunkan jumlah data normal yang keliru diprediksi sebagai outlier dari 5 data menjadi 4 data. Mengingat distribusi kelas target pada data yang digunakan sangat tidak seimbang (imbalanced), pengurangan satu kesalahan deteksi saja sudah memberikan kontribusi matematis yang signifikan terhadap peningkatan metrik F1-Score secara keseluruhan.

Di sisi lain, algoritma Isolation Forest yang mendeteksi 28 anomali justru tidak memberikan peningkatan performa pada metrik F1-Score. Hal ini mengindikasikan bahwa karena Isolation Forest bekerja secara multivariat, beberapa titik data yang diisolasi kemungkinan besar merupakan legitimate extreme, yakni nilai ekstrem yang valid dan sebenarnya mengandung informasi penting untuk memisahkan antar kelas data. Penghapusan data valid tersebut berpotensi mengurangi keberagaman informasi pada data latih tanpa memberikan manfaat klasifikasi yang signifikan. Meskipun nilai AUC-ROC pada skenario Isolation Forest (0,9646) sedikit meningkat dibandingkan baseline (0,9535), peningkatannya tidak cukup konsisten untuk dapat memperbaiki metrik F1-Score.

Temuan ini sejalan dengan literatur yang ada. Yaro et al. (2024) menunjukkan bahwa Modified Z-Score dengan MAD sebagai penduga skala (scale estimator) memberikan performa yang konsisten pada data deret waktu (time-series). Selain itu, Song dan Xia (2024) menyebutkan bahwa untuk data dengan distribusi tidak normal, metode berbasis median cenderung lebih efektif dibandingkan metode berbasis mean atau algoritma machine learning yang tidak mempertimbangkan asumsi distribusi data.

Sebagai simpulan, penelitian ini menunjukkan bahwa pemilihan metode deteksi outlier yang tepat sangat bergantung pada karakteristik data. Untuk data time-series gelombang laut yang distribusinya cenderung tidak normal, Modified Z-Score terbukti lebih unggul. Namun demikian, perlu dicatat bahwa perbedaan performa antar metode dalam eksperimen ini relatif kecil, yang menandakan bahwa faktor lain seperti jumlah data,

pemilihan fitur, dan jenis algoritma klasifikasi juga memiliki peran penting dalam menentukan performa akhir pemodelan.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Penelitian ini menyimpulkan bahwa pemilihan metode deteksi pencilan (outlier) memberikan dampak langsung terhadap kualitas data dan performa model klasifikasi pada data ketinggian gelombang laut. Hasil eksperimen menunjukkan bahwa metode Modified Z-Score lebih efektif dibandingkan Isolation Forest untuk menangani karakteristik data oseanografi dari sensor SAR yang memiliki distribusi tidak normal dan cenderung condong ke kanan (right-skewed). Modified Z-Score terbukti lebih unggul karena sifatnya yang tangguh (robust) terhadap nilai ekstrem melalui penggunaan median dan Median Absolute Deviation (MAD), sehingga mampu mengidentifikasi noise secara lebih presisi.

Secara empiris, penerapan Modified Z-Score berhasil meningkatkan kinerja model Random Forest dengan nilai F1-Score mencapai 0,7880, lebih tinggi dibandingkan skenario baseline dan Isolation Forest yang hanya mencapai 0,7746. Peningkatan ini didorong oleh kemampuan Modified Z-Score dalam menekan angka False Positive, yaitu mengurangi jumlah data normal yang salah terdeteksi sebagai outlier. Meskipun Isolation Forest menunjukkan kemampuan diskriminasi yang baik melalui nilai AUC-ROC yang tinggi, metode ini cenderung mengisolasi data ekstrem yang valid (legitimate extreme), sehingga tidak memberikan peningkatan signifikan pada akurasi klasifikasi kelas minoritas. Dengan demikian, dapat disimpulkan bahwa efektivitas deteksi outlier sangat bergantung pada kesesuaian antara mekanisme kerja algoritma dengan karakteristik distribusi fitur dalam dataset.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dipertimbangkan untuk pengembangan penelitian selanjutnya. Pertama, pengujian dampak preprocessing terhadap kualitas data dapat diperluas dengan menggunakan algoritma klasifikasi selain Random Forest, seperti Support Vector Machine (SVM) atau Gradient Boosting, guna mengevaluasi konsistensi performa pada arsitektur model yang berbeda. Selain itu, variasi strategi penanganan outlier juga perlu dieksplorasi secara lebih mendalam. Penggunaan pendekatan seperti capping (pembatasan nilai) atau transformasi data (misalnya transformasi Log atau Box-Cox) dapat diuji sebagai alternatif dari strategi

penghapusan (removal) untuk meminimalisir risiko hilangnya informasi krusial dari nilai ekstrem yang bersifat valid. Lebih lanjut, optimalisasi parameter (hyperparameter tuning), khususnya pencarian rentang nilai contamination yang paling ideal pada algoritma Isolation Forest, sangat disarankan agar proses isolasi anomali tidak secara keliru mengeliminasi data yang representatif. Terakhir, mengingat keterbatasan penelitian ini yang hanya berfokus pada dimensi deret waktu (time-series), penambahan fitur spasial atau lokasi geografis dapat dilakukan di masa mendatang untuk memberikan analisis yang lebih komprehensif mengenai pola fluktuasi anomali gelombang laut.

DAFTAR PUSTAKA

- [1] D. M. Hawkins, *Identification of Outliers*. London, UK: Chapman and Hall, 1980.
- [2] S. Khan, M. Hemer, E. Echevarria, and E. King, "Australian Ocean Surface Waves Dataset from SAR," *Geoscience Data Journal*, vol. 11, pp. 638–654, 2024.
- [3] B. Iglewicz and D. Hoaglin, *How to Detect and Handle Outliers*. Milwaukee, WI, USA: ASQC Quality Press, 1993.
- [4] F. T. Liu, K. M. Ting, and Z. H. Zhou, "Isolation Forest," in *Proceedings of the 2008 IEEE International Conference on Data Mining*, Pisa, Italy, 2008, pp. 413–422.
- [5] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Waltham, MA, USA: Morgan Kaufmann, 2012.
- [6] V. Chandola, A. Banerjee, and V. Kumar, "Anomaly detection: A survey," *ACM Computing Surveys*, vol. 41, no. 3, pp. 1–58, 2009.
- [7] C. C. Aggarwal, *Outlier Analysis*, 2nd ed. Springer, 2016.
- [8] X. Zhang, Z. Yuan, and D. Miao, "Outlier detection using three-way neighborhood characteristic regions and corresponding fusion measurement," *IEEE Transactions on Knowledge and Data Engineering*, 2023.
- [9] V. Barnett and T. Lewis, *Outliers in Statistical Data*, 3rd ed. John Wiley & Sons, 1994.
- [10] A. S. Yaro, F. Maly, P. Prazak, and K. Maly, "Outlier detection performance of a modified Z-score method in time-series RSS observation with hybrid scale estimators," *IEEE Access*, vol. 12, pp. 12785–12796, 2024, doi: 10.1109/ACCESS.2024.3356731.
- [11] Q. Song and S. Xia, "Research on the effectiveness of different outlier detection methods in common data distribution types," *Journal of Computer Technology and Applied Mathematics*, vol. 1, no. 1, pp. 13–25, 2024, doi: 10.5281/zenodo.10888672.
- [12] C. S. K. Dash, A. K. Behera, S. Dehuri, and A. Ghosh, "An outliers detection and elimination framework in classification task of data mining," *Decision Analytics Journal*, vol. 6, p. 100164, 2023, doi: 10.1016/j.dajour.2023.100164.

LAMPIRAN

Tabel Kontribusi Anggota Tim

No	Nama	Tugas dan Tanggung Jawab	Kontribusi (%)
1	Ade Putri Tifani	Menyusun Bagian 2.4 dan Subbab 3.1 Alur Penelitian	14.3%
2	Natasya Felisita Br Ginting	Menyusun Bagian 1.2 - 1.4 dan Subbab 3.2 Deskripsi Dataset	14.3%
3	Memory Simanjuntak	Menyusun Bagian 2.5 serta revisi Bab 1 dan Bab 2	14.3%
4	Silvia	Menyusun Bagian 2.1 serta revisi Bab 1 dan Bab 2	14.3%
5	Nadya Shafwah Yusuf	Menyusun Bagian 2.2 dan Subbab 3.3.1–3.3.2 terkait pembagian data dan metode yang digunakan	14.3%
6	Mega Zayyani	Menyusun Bagian 2.3 dan Subbab 3.3.4 terkait metrik evaluasi	14.3%
7	Yuni Okta Safitri	Menyusun Bagian 1.1 dan Subbab 3.3.3 terkait algoritma klasifikasi	14.3%
Total			100%

Google Collab : [COLLAB EKSPERIMEN](#)

Repository Github : <https://github.com/nadshafy/DataMining-Project-Outlier-OceanWave>